

Recomendaciones de Negocio — Venta Cruzada de Seguros de Vehículo

Reto 2 — IA avanzada en Business Analytics | Odisea Data

Autor: Judit Giravent

Audiencia: Dirección Comercial y Marketing

1. Contexto

Una compañía de seguros de salud dispone de **381.109 clientes** y quiere venderles un **seguro de vehículo** (venta cruzada). El reto: **contactar solo a los clientes con mayor probabilidad de compra** para no malgastar presupuesto.

Solución propuesta: un modelo de IA (LightGBM) que asigna a cada cliente una **probabilidad de compra** entre 0 y 1, con una capacidad predictiva del **85.7%** (AUC-ROC).

2. Hallazgo principal — El "cliente ideal"

El análisis revela un patrón clarísimo. El cliente con **mayor probabilidad de compra** cumple 3 condiciones:

Condición	Valor ideal
 Vehículo con daños previos	<code>Vehicle_Damage = 1</code>
 No tiene seguro de vehículo actualmente	<code>Previously_Insured = 0</code>
 Edad intermedia	Entre 30 y 50 años

Tasa de conversión de este perfil: ~23%

Tasa de conversión del resto: ~1%

👉 **Concentrar los esfuerzos en este segmento multiplica la eficiencia de las campañas por 20.**

3. Recomendaciones accionables

Recomendación 1 — Excluir clientes ya asegurados

Acción: eliminar de todas las campañas a los clientes con `Previously_Insured = 1`.

Justificación:

- Su tasa de conversión es **~0.1%** (1 de cada 1.000).
- Representan más del **45% de la base de clientes**.
- Contactarles genera coste sin retorno.

Impacto esperado:

- Reducción del **~45%** en costes de contacto.
- Aumento del **ROI de campaña** por concentración en el público objetivo.

Recomendación 2 — Priorizar clientes con daños previos en el vehículo

Acción: crear una **campaña específica** para clientes con `Vehicle_Damage = 1`.

Justificación:

- Su tasa de conversión es **~23%** frente al **~0.5%** de los clientes sin daños.
- Este perfil suele estar predispuesto a renovar o complementar su protección.

Impacto esperado:

- Multiplicar por **~46** la tasa de conversión frente al segmento sin daños.
- Justifica una **inversión publicitaria más agresiva** en este segmento.

Recomendación 3 — Segmentar las campañas por probabilidad predicha

Acción: usar el modelo para clasificar a cada cliente en 5 segmentos y aplicar **una estrategia distinta por segmento**.

Segmento	Probabilidad	% de la base	Acción recomendada	Canal
 Muy alto	80-100%	~1%	Contacto personalizado (llamada + email)	Agente comercial
 Alto	60-80%	~3%	Email personalizado + llamada de seguimiento	Email + teléfono
 Medio	40-60%	~7%	Email marketing con contenido educativo	Email
 Bajo	20-40%	~17%	Email masivo con bajo coste	Email automatizado
 Muy bajo	0-20%	~72%	No contactar	—

Impacto esperado:

- Concentrar el **80% del esfuerzo comercial** en el **11% de clientes** con mayor probabilidad.
- Ahorro estimado: **~70% del presupuesto de contacto** actual.

Recomendación 4 — Optimizar el canal de venta

Acción: analizar qué códigos de `Policy_Sales_Channel` tienen mejor tasa de conversión y **reasignar presupuesto** hacia los más efectivos.

Justificación:

- No todos los canales convierten igual. Algunos canales muestran tasas muy superiores al promedio.
- El modelo aprende automáticamente qué canales son más predictivos.

Impacto esperado:

- Mejora del **coste por adquisición (CPA)** al concentrar inversión en canales efectivos.

Recomendación 5 — Personalizar la oferta según prima anual

Acción: ajustar el producto ofrecido en función de la prima anual del cliente (`Annual_Premium`).

Justificación:

- Los clientes con **primas más altas** muestran mayor propensión a productos complementarios.
- Ofrecer el mismo producto a todos genera fatiga y baja respuesta.

Impacto esperado:

- Aumento del **ticket medio** por cliente mediante ofertas mejor ajustadas a su perfil.

4. Plan de implementación sugerido

Fase	Plazo	Acciones
1. Piloto	Mes 1	Lanzar campaña al segmento "Muy alto" (1% de la base) y medir conversión real vs predicha.
2. Validación	Mes 2	Comparar resultados con un grupo de control sin modelo. Calcular el ROI incremental.
3. Escalado	Mes 3-4	Extender la campaña a los segmentos "Alto" y "Medio". Automatizar el scoring diario.
4. Optimización	Mes 5+	Reentrenar el modelo mensualmente con los datos reales de conversión. Añadir nuevas variables.

5. KPIs para medir el impacto

KPI	Valor actual estimado	Objetivo tras el modelo
Tasa de conversión global	~12%	~18-20%
Coste por adquisición (CPA)	100% (baseline)	-40%

KPI	Valor actual estimado	Objetivo tras el modelo
ROI de campaña	100% (baseline)	+150-200%
Clientes contactados por 1.000€	100%	Concentración 10x en segmentos top
Pólizas adicionales / mes	—	+30-50%

(Los valores objetivo son estimaciones basadas en la capacidad predictiva del modelo y deben validarse con el piloto).

6. Riesgos y cómo mitigarlos

Riesgo	Mitigación
Falsos positivos altos (clientes que el modelo dice que comprarán y no lo hacen)	Empezar por el segmento "Muy alto" (mayor precisión) y escalar gradualmente.
Sesgo por antigüedad (vintage influye poco)	Añadir variables temporales y de comportamiento al modelo.
Cambios en el mercado (nuevos competidores, regulación)	Reentrenar el modelo mensualmente para capturar la evolución.
Fatiga de campaña en clientes recurrentes	Limitar el número de contactos por cliente y mes.

7. Recomendación final

El modelo desarrollado ofrece un **retorno de inversión muy alto** con un coste de implementación mínimo:

- 🎯 **No requiere infraestructura compleja:** puede desplegarse como una API sencilla o incluso con hojas de cálculo en la fase piloto.
- 📊 **Permite empezar pequeño:** un piloto con solo el 1% de la base permite validar el impacto en 4-6 semanas.
- 🔄 **Es escalable:** el mismo modelo puede aplicarse a otros productos de venta cruzada (hogar, vida, etc.).

Conclusión: la aplicación de este modelo permite transformar una campaña masiva de bajo retorno en una **estrategia quirúrgica de alto impacto**, alineada con el objetivo de negocio de maximizar el valor del cliente (Customer Lifetime Value).

Este documento forma parte del Reto 2 — Implementación de algoritmos avanzados de IA en Business Analytics del curso Business Intelligence y Big Data de Odisea Data.